

EQUIPO	PRACTICA 2.
INTEGRANTES • Cordova Colorado Fernanda Paola • Correa Ortiz Eduardo Samuel • Jasso Escamilla Alexis Yair • Ortiz Rosales Anegel Leonardo • Ruiz Dominguez Jeferson Iram	FGSTI 2do Parcial Infraestructura de Inteligencia de Negocios

I. ANALICE EL TEMA Y COMENTE CON SU EQUIPO

Almacenes de datos y mercados de datos

La herramienta tradicional para analizar datos corporativos durante las últimas dos décadas ha sido el almacén de datos. Un **almacén de datos** es una base de datos que almacena la información actual e histórica de interés potencial para los encargados de tomar decisiones en la compañía. Los datos se originan en muchos sistemas básicos de transacciones operacionales, como los sistemas de ventas, las cuentas de clientes, la manufactura, y pueden incluir datos de transacciones de sitios Web. El almacén de datos extrae los datos actuales e históricos de varios sistemas operacionales dentro de la organización. Estos datos se combinan con los datos de fuentes externas y se transforman al corregir los datos imprecisos e incompletos y reestructurar los datos para generar informes gerenciales y realizar análisis antes de cargarlos en el almacén de datos. El almacén de datos pone los datos a disposición de todos según sea necesario, pero no se puede alterar. Un sistema de almacén de datos también provee un rango de herramientas de consulta ad hoc y estandarizadas, herramientas analíticas y facilidades de informes gráficos.

A menudo las empresas crean almacenes de datos a nivel empresarial, donde un almacén de datos central da servicio a toda la organización, o crean almacenes de datos más pequeños y descentralizados conocidos como mercados de datos. Un **mercado de datos** es un subconjunto de un almacén de datos, en el cual se coloca una porción sintetizada o con alto grado de enfoque en los datos de la organización en una base de datos separada para una población específica de usuarios. Por ejemplo, una compañía podría desarrollar mercados de datos sobre marketing y ventas para lidiar con la información de los clientes. El vendedor de libros Barnes & Noble solía mantener una serie de mercados de datos: uno para los datos sobre los puntos de venta en las tiendas minoristas, otro para las ventas de las librerías universitarias y un tercero para las ventas en línea.

Hadoop

Los productos de DBMS relacionales y almacenes de datos no se adaptan bien para organizar y analizar Big Data o datos que no caben fácilmente en las columnas y filas utilizadas en sus modelos de datos. Para manejar datos no estructurados y semiestructurados en grandes cantidades, así como datos estructurados, las organizaciones usan **Hadoop**, que es un marco de trabajo de software de código abierto, administrado por la Fundación de Software Apache, lo que permite el procesamiento paralelo distribuido de enormes cantidades de datos a través de computadoras económicas. Descompone un problema de Big Data en varios subproblemas, los distribuye entre miles de nodos de procesamiento de computadoras económicas y luego combina el resultado en un conjunto de datos de menor tamaño que es más fácil de analizar. Tal vez usted ya haya usado Hadoop para encontrar la mejor tarifa aérea en Internet, obtener indicaciones para llegar a un restaurante, realizar una búsqueda en Google o conectarse con un amigo en Facebook. Hadoop consta de varios servicios clave: el sistema de archivos

distribuidos Hadoop (HDFS) para almacenamiento de datos y MapReduce para procesamiento de datos en paralelo de alto rendimiento. HDFS enlaza entre sí los sistemas de archivos en los numerosos nodos en un clúster Hadoop para convertirlos en un gran sistema de archivos. MapReduce de Hadoop se inspiró en el sistema MapReduce de Google para desglosar el procesamiento de enormes conjuntos de datos y asignar trabajo a los diversos nodos en un clúster. HBase, la base de datos no relacional de Hadoop, ofrece un acceso rápido a los datos almacenados en HDFS y una plataforma transaccional para ejecutar aplicaciones en tiempo real de alta escala. Hadoop puede procesar grandes cantidades de cualquier tipo de datos, incluyendo datos transaccionales estructurados, datos poco estructurados como las fuentes de Facebook y Twitter, datos complejos como los archivos de registro de servidor Web y datos de audio y video no estructurados. Hadoop se ejecuta en un clúster de servidores económicos y pueden agregarse o eliminarse procesadores según sea necesario. Las empresas usan Hadoop para analizar volúmenes muy grandes de datos, así como para un área de concentración para datos no estructurados y semiestructurados antes de cargarlos en un almacén de datos. Facebook almacena gran parte de sus datos en un enorme clúster Hadoop, que contiene cerca de 100 petabytes, alrededor de 10,000 veces más información que la Biblioteca del Congreso estadounidense. Yahoo usa Hadoop para rastrear el comportamiento de los usuarios de modo que pueda modificar su página de inicio y adaptarla a sus intereses. La empresa de investigación de ciencias de la vida NextBio usa Hadoop y HBase para procesar datos para empresas farmacéuticas que realizan investigación genómica. Los principales distribuidores de bases de datos como IBM, Hewlett-Packard, Oracle y Microsoft tienen sus propias distribuciones de software de Hadoop. Otros distribuidores ofrecen herramientas para meter y sacar datos de Hadoop, o para analizarlos dentro de Hadoop.

Computación en memoria

Otra forma de facilitar el análisis de Big Data es utilizar la **computación en memoria**, que depende principalmente de la memoria principal (RAM) de la computadora para el almacenamiento de datos (los DBMS convencionales usan sistemas de almacenamiento de datos). Los usuarios acceden a los datos almacenados en la memoria principal del sistema, con lo cual se eliminan los cuellos de botella por los procesos de recuperación y lectura de datos en una base de datos tradicional basada en discos, y se reducen de manera drástica los tiempos de respuesta de las consultas. El procesamiento en memoria hace posible que conjuntos muy grandes de datos, del tamaño de un mercado de datos o de un almacén pequeño de datos, residan totalmente en la memoria. Los cálculos de negocios complejos que solían tardar horas o días pueden completarse en cuestión de segundos, y esto puede lograrse incluso en dispositivos portátiles

Con los avances en la tecnología de hardware de computadora contemporánea que hacen posible el procesamiento en memoria, como los poderosos procesadores de alta velocidad, el procesamiento multinúcleo y los precios cada vez menores de la memoria de computadora. Estas tecnologías ayudan a las empresas a optimizar el uso de la memoria y aceleran el rendimiento del procesamiento, a la vez que reducen los costos.

Los principales productos comerciales para la computación en memoria son: High Performance Analytics Appliance (HANA) de SAP, y Oracle Exalytics. Cada uno ofrece un conjunto de componentes de software integrados, incluyendo software de base de datos en memoria y software de análisis especializado, que se ejecutan en hardware optimizado para el trabajo de cómputo en memoria.


Plataformas analíticas

Los distribuidores de bases de datos comerciales han desarrollado **plataformas analíticas** especializadas de alta velocidad que utilizan tecnología tanto relacional como no relacional y están optimizadas para analizar conjuntos de datos de gran tamaño. Las plataformas analíticas como IBM Netezza y Oracle Exadata cuentan con sistemas de hardware-software preconfigurados que están diseñados de manera específica para el procesamiento de consulta y los análisis. Por ejemplo, IBM Netezza tiene componentes de base de datos, servidor y almacenamiento estrechamente integrados que manejan consultas analíticas complejas 10 a 100 veces más rápido que los sistemas tradicionales. Las plataformas analíticas también incluyen sistemas en memoria y sistemas de administración de bases de datos no relacionales. Ahora, las plataformas analíticas están disponibles como servicios en la nube.

La figura 6.12 ilustra una infraestructura de inteligencia de negocios contemporánea que usa las tecnologías que acabamos de describir. Los datos actuales e históricos se extraen de varios sistemas operacionales junto con datos Web, datos generados por máquinas, datos de audio/visuales no estructurados y datos provenientes de fuentes externas, que se han reestructurado y organizado para generación de informes y análisis. Los clústeres Hadoop

preprocesan los Big Data para usarlos en el almacén de datos, mercados de datos o en una plataforma analítica, o para que los usuarios avanzados los consulten de manera directa. Los resultados incluyen informes y tableros de control, así como resultados de las consultas.

FIGURA 6.12 INFRAESTRUCTURA CONTEMPORÁNEA DE INTELIGENCIA DE NEGOCIOS



II. SEGÚN EL DIAGRAMA ANTERIOR Y LA LECTURA PREVIA DE CONCEPTOS; CREE UN ESCENARIO DONDE SE PUEDA UTILIZAR ESTA INFRAESTRUCTURA DE NEGOCIOS DENTRO DEL AMBITO DE SU PROYECTO (TI /GIRO EMPRESARIAL)

En este caso, los campos agrícolas cuentan con sensores IoT instalados en diferentes zonas del terreno para recopilar información sobre variables como humedad del suelo, temperatura, niveles de nutrientes, cantidad de lluvia y crecimiento de las plantas. Todos estos datos son enviados automáticamente a servidores en la nube, donde se almacenan en un almacén de datos (Data Warehouse). Este almacén integra información histórica de las cosechas, datos climáticos, registros de riego, uso de fertilizantes y producción obtenida en temporadas anteriores. De esta manera, los administradores agrícolas pueden analizar el comportamiento de los cultivos a lo largo del tiempo y tomar mejores decisiones.

Para manejar grandes cantidades de información generadas por sensores y dispositivos, la empresa puede utilizar tecnologías como Hadoop, que permite procesar grandes volúmenes de datos de manera distribuida. Esto facilita analizar patrones en los cultivos, identificar condiciones óptimas de crecimiento y detectar posibles problemas como sequías, plagas o enfermedades en las plantas.

Además, mediante plataformas analíticas en la nube, los agricultores pueden visualizar los datos a través de tableros de control o dashboards, que muestran indicadores importantes como rendimiento por hectárea, consumo de agua, predicciones climáticas y estimaciones de cosecha. Estas herramientas permiten tomar decisiones rápidas y basadas en datos, por ejemplo, ajustar el riego automático o aplicar fertilizantes solo en zonas específicas del campo.

El uso de computación en memoria también puede mejorar la velocidad de análisis, permitiendo que los datos se procesen casi en tiempo real. Esto ayuda a reaccionar rápidamente ante cambios climáticos o condiciones desfavorables en los cultivos.

La combinación de almacenes de datos, Hadoop, análisis de Big Data y computación en la nube permite modernizar la agricultura mediante el uso de datos inteligentes. Gracias a esta infraestructura, las empresas agrícolas pueden mejorar la productividad, reducir costos, optimizar el uso de recursos como agua y fertilizantes, y aumentar la eficiencia en la producción de alimentos.

